



Tratamiento de Señales

Version 2022-2

PARTE 1

# Detección de Bordes

[ Capítulo 7 ]

**Dr. José Ramón Iglesias**

DSP-ASIC BUILDER GROUP  
Director Semillero TRIAC  
Ingeniería Electronica  
Universidad Popular del Cesar





Cielo

Mar

Taza

Mesa








Cielo

Mar

Mesa




Cielo

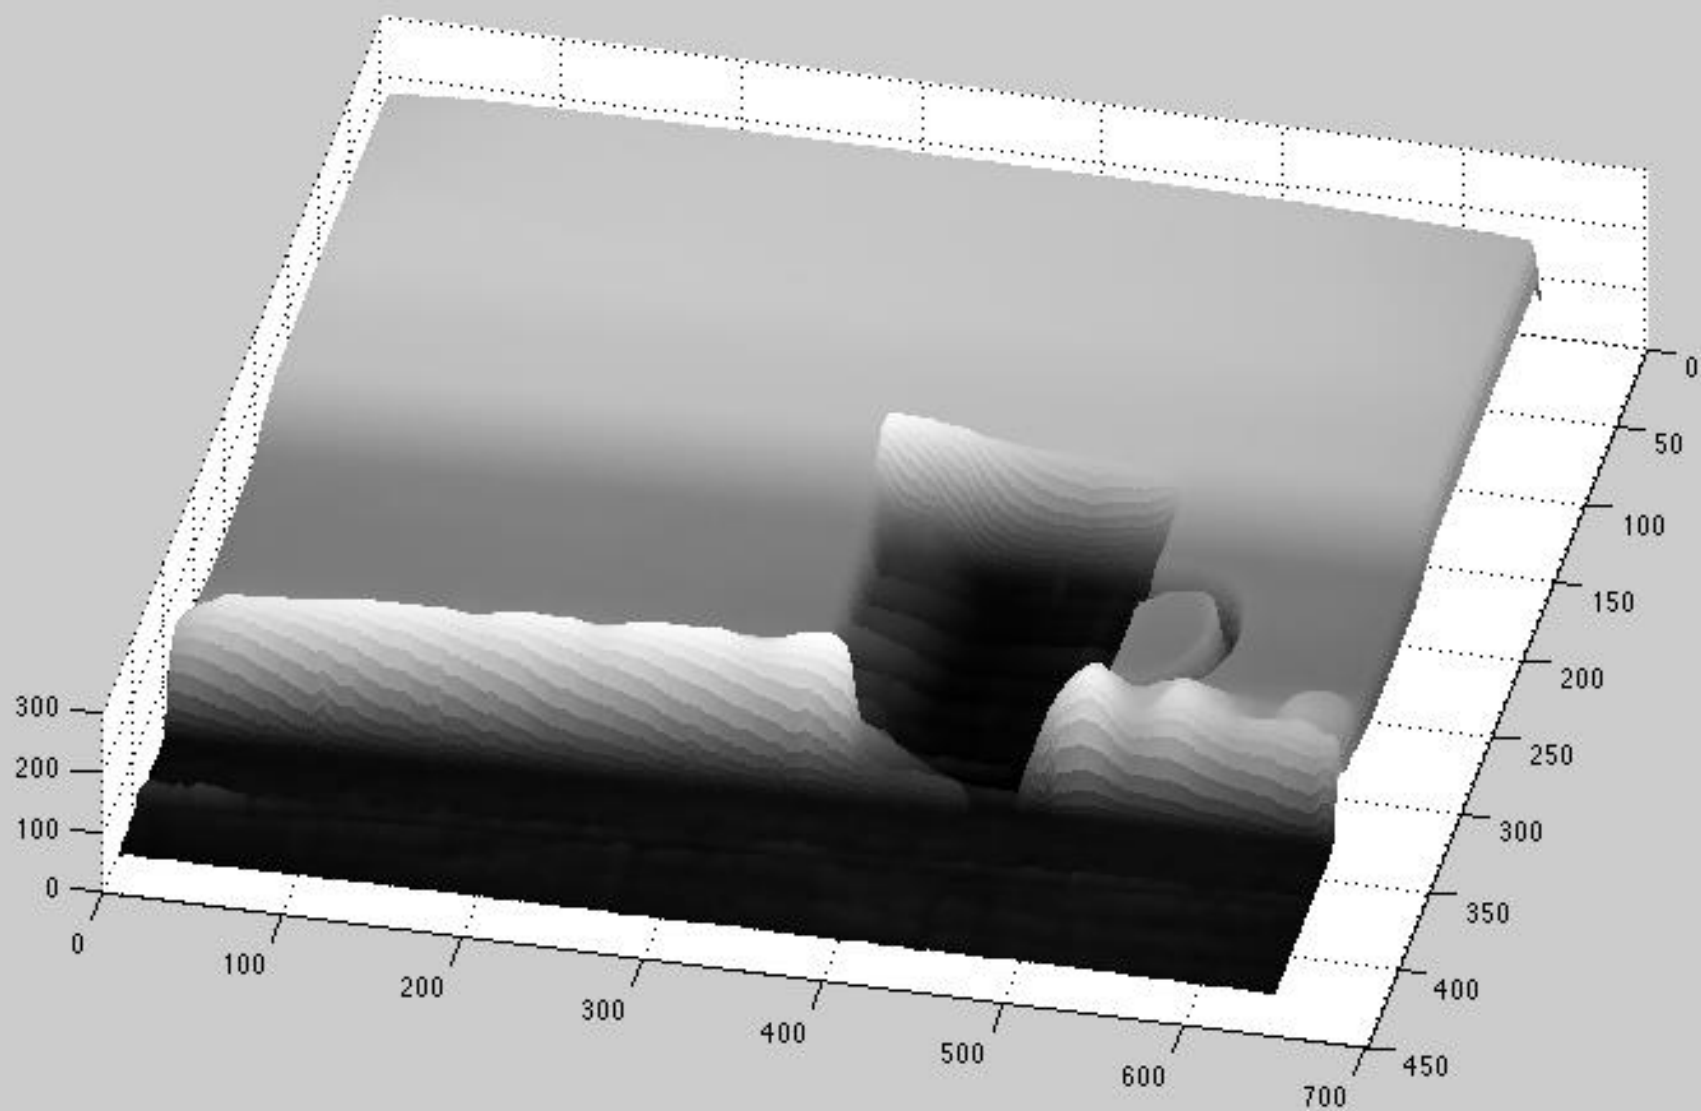
Mar

Taza

Mesa







# Los bordes de una imagen se calculan a partir del Gradiente

La supresión non-maximum es una técnica que permite adelgazar los bordes basándose en el gradiente.

La derivada de una señal continua proporciona las variaciones locales con respecto a la variable, de forma que el valor de la derivada es mayor cuanto más rápidas son estas variaciones. En el caso de funciones bidimensionales  $f(x,y)$ , la derivada es un vector que apunta en la dirección de la máxima variación de  $f(x,y)$  y cuyo módulo es proporcional a dicha variación. Este vector se denomina gradiente y se define:

$$f'(x) = \frac{\partial f}{\partial x} = \lim_{\Delta x \rightarrow 0} \frac{f(x + \Delta x) - f(x)}{\Delta x}$$

$$\nabla f(x,y) = \left[ \frac{\partial f}{\partial x}, \frac{\partial f}{\partial y} \right]$$

# Los bordes de una imagen se calculan a partir del Gradiente

En las imágenes el  $\Delta x$  más pequeño es 1:

En el caso bidimensional discreto, las distintas aproximaciones del operador gradiente se basan en diferencias entre los niveles de grises de la imagen. La derivada parcial  $f_x(x,y)$  (gradiente de fila  $G_f(i,j)$ ) puede aproximarse por la diferencia de píxeles adyacentes de la misma fila.

$$G_i(i, j) = X(i + 1, j) - X(i, j)$$

GRADIENTE EN  
DIRECCIÓN i

-1	1
----	---

$$G_j(i, j) = X(i, j + 1) - X(i, j)$$

GRADIENTE EN  
DIRECCIÓN j

-1
1



$$G(i, j) = \sqrt{(G_i(i, j))^2 + (G_j(i, j))^2}$$

MÁGNITUD



$$A(i, j) = \arctan \frac{G_j(i, j)}{G_i(i, j)}$$

ÁNGULO

# Los bordes de una imagen se calculan a partir del Gradiente

En términos generales:

Máscara que realiza el gradiente y filtra el ruido (filtro pasa bajos)


**h**

$$\mathbf{G}_i = \mathbf{X} * \mathbf{h}^T$$


GRADIENTE EN DIRECCIÓN i

$$\mathbf{G}_j = \mathbf{X} * \mathbf{h}$$

GRADIENTE EN DIRECCIÓN j


$$G(i, j) = \sqrt{(G_i(i, j))^2 + (G_j(i, j))^2}$$

MAGNITUD


$$A(i, j) = \arctan \frac{G_j(i, j)}{G_i(i, j)}$$

ÁNGULO

# Los bordes de una imagen se calculan a partir del Gradiente

En las imágenes el  $\Delta x$  más pequeño es 1:

$$\mathbf{h} = [-1, 1]$$



$$G_i(i, j) = X(i+1, j) - X(i, j)$$

GRADIENTE EN  
DIRECCIÓN i

$$G_j(i, j) = X(i, j+1) - X(i, j)$$

GRADIENTE EN  
DIRECCIÓN j



$$G(i, j) = \sqrt{(G_i(i, j))^2 + (G_j(i, j))^2}$$

MAGNITUD



$$A(i, j) = \arctan \frac{G_j(i, j)}{G_i(i, j)}$$

ÁNGULO

# Máscaras usadas para calcular el Gradiente

$$\mathbf{h}_{\text{Sobel}} = \begin{bmatrix} -1 & 0 & +1 \\ -2 & 0 & +2 \\ -1 & 0 & +1 \end{bmatrix}$$

El operador Sobel (-2 0 +2), se supone que es más sensible a los bordes diagonales que el de Prewitt aunque en la práctica hay poca diferencia entre ellos

$$\mathbf{h}_{\text{Prewitt}} = \begin{bmatrix} -1 & 0 & +1 \\ -1 & 0 & +1 \\ -1 & 0 & +1 \end{bmatrix}$$


En el operador Prewitt (-1 0 +1) se involucran a los vecinos de filas / columnas

$$h_{\text{Gauss}}(m, n) = m \cdot e^{-\frac{m^2 + n^2}{2\sigma^2}}$$


adyacentes para proporcionar mayor inmunidad al ruido

# Máscaras Gaussianas

$$h(x, y) = \frac{1}{2\pi\sigma^2} \cdot e^{-\frac{m^2+n^2}{2\sigma^2}}$$




FILTRO PASABAJOS



$$\frac{\partial h}{\partial x}$$

GRADIENTE EN  
DIRECCIÓN x



$$\frac{\partial h}{\partial y}$$

GRADIENTE EN  
DIRECCIÓN y

# Ejemplos





# Ejemplos



Original




Sobel




Prewitt



Gaussian



Gaussiana  
(escala logarítmica)



Threshold = 3